# CapiTainS

Thibault Clérice

Décembre 6, 2017

#### 1. La norme

- CapiTainS a pour objectif de rendre un texte disponible à la citation à travers une série de petites règles que doivent suivre les documents
- Suite d'outils et une norme
- ► Source du cours : https://github.com/Capitains/DH2016

### 2. Les identifiants



Figure 1: Norme basée sur identifiant CTS

### 3. La structure des dossiers

- Un dossier corpus avec un sous dossier data
- Un dossier avec l'identifiant du textgroup
  - et un fichier cts.xml pour les métadonnées
- Un dossier avec l'identifiant work
  - et un fichier cts.xml pour les métadonnées
  - et les fichiers d'éditions, de traductions et de commentaire

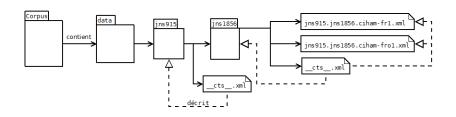


Figure 2: Structure

# 4. Métadonnées du textgroup

## 5. Métadonnées du work et de l'édition

```
https://en.wikipedia.org/wiki/ISO 639:f
<work xmlns="http://chs.harvard.edu/xmlns/cts"</pre>
    groupUrn="urn:cts:froLit:jns915"
    urn="urn:cts:froLit:jns915.jns1856" xml:lang="fro">
    <title xml:lang="fre">Vie de Saint Martin</title>
    <edition workUrn="urn:cts:froLit:jns915.jns1856" urn="u"</pre>
        <label xml:lang="fre">Vie de Saint Martin</label>
        <description xml:lang="fre">Édition du CIHAM basé s
    </edition>
</work>
```

### 5 bis Métadonnées avancées :

```
<textgroup xmlns="http://chs.harvard.edu/xmlns/cts"</pre>
        xmlns:cpt="http://purl.org/capitains/ns/1.0#"
        xmlns:saws="http://purl.org/saws/ontology#"
        xmlns:dc="http://purl.org/dc/elements/1.1/"
        xmlns:dct="http://purl.org/dc/terms/"
        xmlns:schema="http://schema.org/"
        urn="urn:cts:froLit:jns915">
  <groupname xml:lang="fre">Wauchier de Denain
  <cpt:structured-metadata>
    <dc:type>schema:Person</dc:type>
    <schema:birthDate>1200</schema:birthDate>
    <schema:deathDate>1299</schema:deathDate>
    <dc:description>Wauchier de Denain est un écrivain fran
    <dc:identifier>https://www.wikidata.org/wiki/Q942529
  </cpt:structured-metadata>
</textgroup>
```

# 6. Un essai de groupe

 $\label{lem:condition} \begin{tabular}{ll} Un textgroup pour Perceval - \\ http://atilf.atilf.fr/gsouvay/dect/download/Perceval.xml \end{tabular}$ 

### 7. Tester

- https://capitains-validator.herokuapp.com/
- ► Pour ceux-lles avec Python3 sur leur ordinateur (Ne fonctionne pas sous windows) :
- ▶ Installer HookTest : sudo pip3 install HookTest
- ▶ Dans le dossier du corpus, ouvrir un terminal et lancer hooktest --console table --scheme tei --verbose 10 .

## 8. Le fichier texte TEI: l'identifiant

- ▶ On mets l'identifiant du texte dans l'attribut @n de
  - /TEI/text/body pour de la TEI normale
  - ► TEI/text/body/div[@type="edition" or @type="translation" or @type="commentary"] pour de l'epidoc
- On met sur ce même tag l'attribut xml:lang avec le code en trois caractères

# 9. Le fichier texte TEI: l'identification des passages

```
<refsDecl n="CTS">
  <cRefPattern
     n="vers" matchPattern="(\w+).(\w+)"
     replacementPattern="#xpath(/tei:TEI/tei:text/tei:bod
     Ce pointeur extrait les vers des poèmes
  </cRefPattern>
  <cRefPattern
     n="poeme" matchPattern="(\w+)"
     replacementPattern="#xpath(/tei:TEI/tei:text/tei:body
      Ce pointeur extrait les poèmes
  </cRefPattern>
</refsDecl>
```

## Exemple

Source : http://atilf.atilf.fr/gsouvay/dect/download/Perceval.xml http://www.atilf.fr/dect/